

Fine-tuning de Stable Diffusion v1.5 para la Generación de Pósteres de Películas

Implementación y entrenamiento mediante técnica LoRA
especializada en géneros de Animación, Terror y Romance.

Autores:

Álvaro Lorenzo Hidalgo

Marcos Ortíz Durán

Universidad Loyola

Sevilla, España

15 de enero de 2026

Índice general

1	Introducción	2
2	Metodología y Datos	2
2.1	Arquitectura del Modelo Base: Stable Diffusion	2
2.2	Dataset de Entrenamiento	2
2.3	Fine-Tuning: Adaptación mediante LoRA	3
3	Experimentos	3
3.1	Entorno de Experimentación	3
3.2	Diseño Experimental	3
3.2.1	Fases de Evaluación	4
3.3	Estructura de Prompts y Resultados	4
4	Resultados	5
4.1	Resultados de Modelos Experimentales	5
4.1.1	Impacto del Rank (Modelo A vs. Modelo B)	5
4.1.2	Impacto del Contexto Semántico (Modelo B vs. Modelo C)	6
4.2	Análisis de la Función de Pérdida	6
4.3	Análisis de Sensibilidad: Pesos y Muestreo	7
4.3.1	Influencia de los Pesos LoRA	7
4.3.2	Convergencia de Pasos de Inferencia	8
5	Conclusiones	8

1 Introducción

Los modelos de difusión han revolucionado la generación text-to-image, pero arquitecturas generalistas como Stable Diffusion v1.5 muestran limitaciones al replicar estructuras rígidas como la cartelería cinematográfica. Este trabajo propone el uso de LoRA (Low-Rank Adaptation) como solución de entrenamiento eficiente. A diferencia del costoso reentrenamiento completo, esta técnica permite incorporar nuevos estilos interviniendo mínimamente en los parámetros del modelo, optimizando así el uso de recursos. El objetivo es desarrollar un adaptador capaz de generar pósters coherentes para los géneros de Terror, Romance y Animación. Mediante el análisis del Rank y la ingeniería de prompts, se busca establecer un flujo de trabajo que equilibre la fidelidad al género con la calidad técnica de la imagen.

2 Metodología y Datos

2.1 Arquitectura del Modelo Base: Stable Diffusion

Stable Diffusion es un modelo generativo basado en *Latent Diffusion Models* (LDM) [1]. Su eficiencia radica en aplicar el proceso de difusión sobre un espacio latente comprimido en lugar del espacio de píxeles.

Componentes de la Arquitectura

El sistema integra tres módulos fundamentales:

1. **Autoencoder Variacional (VAE):** Reduce la dimensionalidad computacional. El *encoder* comprime la imagen de entrada (512×512) a una representación latente compacta para su procesamiento, mientras que el *decoder* reconstruye la imagen final tras el proceso de generación.
2. **U-Net (Denoising Network):** Motor principal de inferencia. Es una red neuronal que predice y sustrae el ruido en el espacio latente iterativamente, utilizando mecanismos de atención para condicionar la generación a partir del texto.
3. **Text Encoder (CLIP):** Procesa los *prompts* de entrada utilizando el modelo pre-entrenado CLIP. Transforma el texto en *embeddings* vectoriales que guían a la U-Net, asegurando la coherencia semántica entre la instrucción y la imagen resultante.

2.2 Dataset de Entrenamiento

Se utilizó el dataset *skvarre/movie-posters*, compuesto por aproximadamente 10,000 carteles de películas y sus metadatos asociados.

Selección y Balanceo de datos

Para evaluar la diferenciación estilística, se filtraron tres géneros: Terror, Romance y Animación. Se aplicó un submuestreo estratificado para garantizar un número equitativo de muestras por clase, mitigando así sesgos hacia los géneros mayoritarios del conjunto original.

Preprocesamiento (Pipeline)

Se implementó un flujo de transformación para adecuar los datos a los requisitos de Stable Diffusion:

1. **Estandarización Visual:** Conversión de imágenes al espacio de color RGB y redimensionado uniforme a 512×512 píxeles.
2. **Generación de Prompts:** Ante la ausencia de descripciones visuales nativas, se sintetizaron *prompts* automatizados combinando los metadatos disponibles:
 - *Estilo 1: A cinematic movie poster in the style of [GENRES], high quality*
 - *Estilo 2: A cinematic movie poster in the style of [GENRES], about [OVERVIEW], high quality*

Esta estructura permite al modelo asociar la estética del póster tanto al género como a la narrativa.

3. **Estructuración:** Consolidación del dataset mediante un archivo de metadatos JSONL, vinculando cada imagen con su descripción para su ingesta directa mediante la librería *diffusers*.

2.3 Fine-Tuning: Adaptación mediante LoRA

La especialización del modelo se realizó mediante **LoRA (Low-Rank Adaptation)**. Esta técnica de *Parameter-Efficient Fine-Tuning* (PEFT) inyecta matrices de bajo rango en las capas de atención de la U-Net, manteniendo congelados los pesos preentrenados para optimizar el coste computacional. El entrenamiento se limitó a estas matrices, alineando los conceptos visuales de los géneros seleccionados (Terror, Romance, Animación) con los *embeddings* textuales; la parametrización específica (tasa de aprendizaje y rango) se detalla en la sección experimental.

3 Experimentos

En este capítulo se detalla el diseño de las pruebas realizadas para evaluar la capacidad de estilización del adaptador LoRA.

3.1 Entorno de Experimentación

Para garantizar la reproducibilidad, los experimentos se ejecutaron en una GPU NVIDIA T4 con 16 GB de VRAM (Google Colab), utilizando Python 3.10 junto con las librerías *diffusers* y PyTorch. Se estableció la semilla de control (*seed*) en **42** para asegurar condiciones idénticas de ruido inicial en todas las pruebas comparativas.

3.2 Diseño Experimental

Se entrenaron tres modelos variando la capacidad de la red (Rank) y la estructura del *prompt*, manteniendo constantes el resto de hiperparámetros para aislar su influencia. Posteriormente, se analizó el impacto de los pesos del adaptador y los pasos de inferencia en la generación final.

A continuación, se detalla la configuración global del entrenamiento (Tabla 3.1) y las particularidades de cada variante (Tabla 3.2).

Tabla 3.1. Configuración general de hiperparámetros de entrenamiento.

Parámetro	Configuración	Parámetro	Configuración
Modelo Base	Stable Diffusion v1.5	Batch Size	2
Resolución	512 × 512 px	Épocas	4
LoRA Rank	128	Precisión	fp16
Learning Rate	1×10^{-4}	Seed	42
Scheduler	Cosine	Max Grad Norm	1.0
Augmentation	Random Flip (H)	Reporte	WandB

Tabla 3.2. Definición de las variantes experimentales.

Modelo	Rank (r)	Estructura del Prompt
Modelo A	32	Solo géneros cinematográficos
Modelo B	128	Solo géneros cinematográficos
Modelo C	128	Géneros + Resumen de la trama (<i>Overview</i>)

3.2.1 Fases de Evaluación

Exp. I: Barrido de Pesos (Weight Sweeping). Se busca el punto de equilibrio en la influencia del adaptador. Se varía el peso del LoRA en el rango $w \in \{0, 0, 0, 3, \dots, 1, 8\}$ para identificar el valor donde el modelo adopta la composición del póster sin degradar la fidelidad anatómica o la nitidez.

Exp. II: Convergencia de Inferencia. Manteniendo $w = 1, 0$, se analiza la relación coste-calidad evaluando los pasos de muestreo $t \in \{5, 15, 30, 50, 100\}$.

Exp. III: Generalización por Géneros. Se evalúa la versatilidad del modelo mediante tres categorías estilísticas opuestas:

Tabla 3.3. Categorías de validación semántica.


Categoría	Concepto	Objetivo de evaluación
Terror	Orfanato / Slasher	Contraste alto, sombras y atmósfera lúgubre.
Animación	Ghibli / Disney	Transformación de texturas realistas a ilustración.
Romance	Drama / Comedia	Iluminación suave y expresividad emocional.

3.3 Estructura de Prompts y Resultados

Para estandarizar la generación, se empleó la plantilla: A cinematic movie poster in the style of [genre], about [overview]. Para ello, combinando diferentes generos y estableciendo una trama, obtendríamos los resultados vistos en Figura 3.1.



(a) *Terror / Drama*



(b) *Romance / Comedia*

Figura 3.1. Resultados visuales preliminares según género y trama.

4 Resultados

En esta sección se evalúa el rendimiento de tres adaptaciones del modelo base usando LoRA para lograr generar pósteres cinematográficos. Se experimentaron con dos variables: la capacidad de la red (*Rank*) y la descripción de la imagen (*Prompting*).


4.1 Resultados de Modelos Experimentales

4.1.1 Impacto del Rank (Modelo A vs. Modelo B)

Al comparar el Modelo A ($r = 32$) con el Modelo B ($r = 128$), se observa que el incremento en el rango permite capturar detalles más finos de la composición visual de un poster cinematográfico.

- El **Modelo A** logra replicar la paleta de colores y el estilo general del género pero no logra captar la composición de un poster cinematográfico debido a la ausencia de título y estructura.
- El **Modelo B** demuestra una mayor similitud a la disposición de un póster, aunque su entrenamiento requiere mayor tiempo de cómputo y genera archivos de pesos más pesados.

Esto se puede apreciar en las imágenes inferiores. Podemos ver como el Modelo A no logra generar una estructura coherente ni el título presente en todos los carteles. Mientras tanto, el modelo B si que genera un resultado muy coherente y semejante a un poster cinematográfico.



4.1.2 Impacto del Contexto Semántico (Modelo B vs. Modelo C)

Entre el modelo B y el C la diferencia consiste en la definición textual de la imagen que se le pasa en el entrenamiento, incluyendo en el modelo C la sinopsis de la película.

En términos generales, no se observan diferencias significativas en la estructura base entre las generaciones de los distintos modelos. No obstante, el Modelo C presenta una acentuación de los rasgos característicos del género asociado. Esto se debe a que el modelo ha logrado asociar con mayor precisión los términos del prompt con su representación visual correspondiente.

Este fenómeno se aprecia en la comparativa de la figura inferior. Mientras que el Modelo B ofrece una interpretación estándar, el Modelo C emplea una paleta de colores más oscura y desaturada para representar el género de terror. Este ajuste demuestra que el modelo no solo ha aprendido la composición de un póster, sino que también ha asimilado la atmósfera y la estética visual que definen a cada género cinematográfico.



4.2 Análisis de la Función de Pérdida

La gráfica mostrada en la Figura 4.3 permite analizar cómo se comportan los tres modelos durante el entrenamiento. Se observa que la pérdida baja repentinamente y después la curva en media disminuye en muy poca medida. Esto indica que el modelo deja de aprender información nueva tras los primeros pasos y se estanca. Este resultado es habitual en técnicas de Fine-Tuning porque el modelo base (SD v1.5) posee un conocimiento muy robusto. El entrenamiento simplemente ajusta ese conocimiento previo hacia el nuevo estilo y por eso la pérdida deja de disminuir notablemente tan pronto.




Figura 4.3. Evolución temporal suavizada (window = 50) de los 3 modelos entrenados de LoRA. La línea azul representa el modelo A, la verde al modelo C y la naranja al modelo B prácticamente coincidente con la anterior.

Para evaluar si realmente el modelo con una época logra aprender el estilo, se realizó una prueba de generación temprana tras la primera época de entrenamiento. El objetivo era determinar si el modelo era capaz de asimilar la estructura de un póster cinematográfico en una etapa inicial del proceso.

Los resultados Figura 4.4 demuestran que, con una sola época, el modelo generará imágenes subóptimas. Los elementos estructurales de la imagen no varían mucho con respecto al modelo original a diferencia del entrenamiento con cuatro épocas. Se confirma, por tanto, que el modelo requiere de un ciclo de entrenamiento más largo para capturar con fidelidad los detalles finos y la disposición espacial característica de los carteles de cine, a pesar de que no se vea reflejado en la evolución del error.



Figura 4.4. Generación del modelo C para una única época de entrenamiento

4.3 Análisis de Sensibilidad: Pesos y Muestreo

Utilizando el Modelo C, se evaluó el impacto de la fuerza del adaptador (w) y la profundidad del muestreo (t) en la calidad final (Figura 4.5).


4.3.1 Influencia de los Pesos LoRA

Existe una correlación directa entre la escala del peso y la fidelidad al formato de póster. Mientras el modelo base ($w = 0,0$) genera interpretaciones genéricas, el incremento de w fuerza la aparición de características aprendidas: atmósfera específica del género y, notablemente, la simulación de bloques tipográficos (títulos y créditos) en la composición, validando la especialización


del modelo.

4.3.2 Convergencia de Pasos de Inferencia

El análisis de pasos muestra que el modelo requiere un mínimo de iteraciones para definir la estructura. Con $t < 15$, el resultado es abstracto o ruidoso. La estabilidad visual (nitidez de bordes y contraste) alcanza su óptimo en $t = 50$; superar este umbral aumenta el coste computacional sin aportar mejoras perceptuales significativas ni corregir artefactos.



(a) Evolución de la influencia del peso LoRA (w).



(b) Evolución de la nitidez según pasos de inferencia (steps).

Figura 4.5. Estudio de influencia de parámetros en el Modelo C. Se observa la aparición de estilo con w creciente (a) y la convergencia de calidad en $t = 50$ (b).

5 Conclusiones

El presente trabajo valida la eficacia de la técnica **LoRA** para la especialización de modelos de difusión (Stable Diffusion v1.5) en dominios creativos complejos, logrando resultados consistentes con un coste computacional reducido. A partir de la experimentación, se derivan las siguientes conclusiones:

Influencia del Rango y Estructura. La capacidad de la red demostró ser determinante para la composición espacial. Mientras rangos bajos ($r = 32$) capturan texturas generales, se evidenció que un rango mayor ($r = 128$) es imprescindible para que el modelo asimile la distribución estructural del póster, específicamente la ubicación de personajes y la simulación de bloques tipográficos.

Riqueza Semántica y Atmósfera. La introducción de sinopsis narrativas (*overviews*) en el entrenamiento (Modelo C) mejoró sustancialmente la coherencia estilística. Se observó una correlación directa entre la densidad semántica del *prompt* y la precisión atmosférica (iluminación y paleta de colores), superando a los modelos entrenados únicamente con etiquetas de género.

Optimización de Inferencia. El análisis de sensibilidad estableció que la configuración óptima reside en un peso de adaptador $w = 1,0$ y 50 pasos de muestreo (t). Valores superiores en t no aportan mejoras perceptuales significativas y tienden a introducir artefactos de saturación.

Limitaciones y Trabajo Futuro. Si bien el sistema logra replicar la maquetación del cartel cinematográfico, la generación de texto legible permanece como una limitación intrínseca de la arquitectura v1.5. Futuras líneas de investigación deberían orientarse hacia la integración de mó-

dulos de control estructural (ControlNet) o el uso de modelos de mayor resolución (SDXL) para abordar la renderización tipográfica.

En definitiva, la metodología propuesta demuestra la viabilidad técnica de automatizar fases conceptuales del diseño gráfico, alineando con éxito la generación algorítmica con los cánones estéticos de la industria cinematográfica.